## ББМО-02-22 Филиппов Л.А

## «Анализ защищенности систем искусственного интеллекта» Практическая работа 4

1. Установка Adversarial Robustness Twoblox(ART) и matplotlib

## 2. Импорт необходимых библиотек

3. Загрузка датасета MNIST

```
3. 3arpy3ka датасета MNIST

# Набор данных MNIST

(x_raw, y_raw), (x_raw_test, y_raw_test), min_, max_ = load_mnist(raw=True)

# Случайная выборка

n_train = pp.shape(x_raw)[0]

num_selection = 10000

random_selection_indices = np.random.choice(n_train, num_selection)

x_raw = x_raw[random_selection_indices]

y_raw = y_raw[random_selection_indices]

1m7.4s

Python
```

4. Предобработка данных

```
4. Предобработка данных

# Отравление обучающей выборки
percent_poison = .33
x_train, y_train = preprocess(x_raw, y_raw)
x_train = no.expand_dims(x_train, axis=3)

x_test, y_test = preprocess(x_raw_test, y_raw_test)
x_test = no.expand_dims(x_test, axis=3)

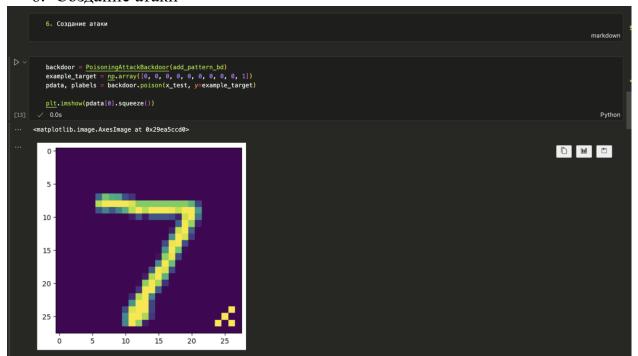
# Перемешивание данных
n_train = no.shape(y_train)[0]
shuffled_indices = no.arange(n_train)
no.random.shuffle(shuffled_indices)
x_train = x_train[shuffled_indices]
y_train = y_train[shuffled_indices]
y_train = y_train[shuffled_indices]

Python

Python
```

5. Функция create model() для создания последовательности из 9 слоев

6. Создание атаки



7. Определение целевого класса атаки

```
7. Определение целевого класса атаки

markdown

targets = to_categorical([9], 10)[0]

v 0.0s

Python
```

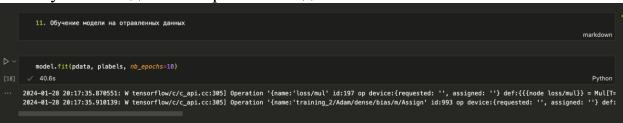
8. Создание модели

## 9. Исполнение атаки

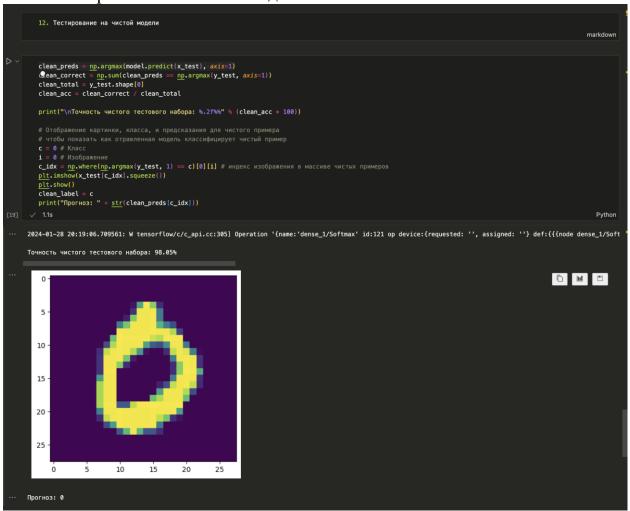
10. Создание отравленных примеров данных



11. Обучение модели на отравленных данных



12. Тестирование на чистой модели



13.Получение результатов атаки на модель

